Descubrimiento de Conocimiento en Bases de Datos (KDD) Aplicado a la Detección y Prevención de Fraude Bancario en Costa Rica

Curso: SINF-633 · Proyecto Final | **Rol:** Analista Sénior de Prevención de Fraude | **Metodología:** Fayyad et al. (1996) | **Fecha:** Octubre 2026

1. Resumen ejecutivo: Convergencia nocturna y de alto monto concentra el 72.5% del fraude

El presente informe técnico documenta la ejecución integral y reproducible de las cinco etapas canónicas del modelo *Knowledge Discovery in Databases* (KDD) propuesto por Fayyad et al. (1996) sobre el registro histórico `transacciones_bancarias.csv` (5 000 operaciones y 11 atributos) de una entidad bancaria costarricense. El estudio responde a la pregunta central del proyecto: **¿qué patrones permiten distinguir transacciones bancarias legítimas de fraudulentas, y cómo puede el banco operacionalizar esos patrones para reducir pérdidas sin degradar la experiencia del cliente legítimo?**

El diagnóstico cuantitativo revela una **tasa global de fraude del 2.18%** (109 transacciones fraudulentas frente a 4 891 legítimas, equivalente a un ratio de desbalance severo de **44.87 : 1**). Pese a su baja frecuencia relativa, el impacto patrimonial es crítico: mientras una operación legítima presenta una mediana de **$56.22** (media de $3 432.16), las transacciones fraudulentas alcanzan una mediana de **$1 374.68** y una media de **$92 477.91**, acumulando pérdidas potenciales por **$10.08 millones** (el 37.51% del volumen monetario total procesado en la muestra). El hallazgo estructural demuestra que el fraude obedece a una firma espacio-temporal y monetaria altamente específica: en la ventana nocturna de **23:00 a 05:59 horas**, el **91.86% de las transacciones superiores a $800 son fraudes reales** (79 de 86 operaciones), mientras que en horario diurno (06:00 a 22:59 horas) ninguna de las 187 transacciones mayores a $800 es fraudulenta (0.00%). En consecuencia, la operacionalización de los modelos supervisados **XGBoost (AUC-ROC = 0.8552, F1 = 0.8108)** y **Random Forest (Precision = 100.0%, Recall = 68.18%)** bajo una arquitectura escalonada de tres niveles permite bloquear en tiempo real más del 94% del capital defraudado con **cero falsos positivos (0.00% de rechazo a clientes legítimos)**.

2. Datos y metodología: Ejecución rigurosa de las cinco etapas del proceso KDD

La metodología se estructuró siguiendo estrictamente el protocolo secuencial de Fayyad et al. (1996), garantizando trazabilidad estadística y ausencia total de fuga de información (*data leakage*) entre los conjuntos de entrenamiento y prueba.

Etapa 1 (Selección) y Etapa 2 (Preprocesamiento y Limpieza)

El archivo `transacciones_bancarias.csv` se cargó en Pandas configurando `parse_dates=['fecha_hora']`. Tras catalogar las 11 variables por naturaleza estadística, se excluyeron del modelado directo los identificadores `id_transaccion` (secuencia 1 a 5 000 sin valor predictivo) e `id_cliente` (alta cardinalidad con 1 444 sujetos únicos donde solo dos clientes registran más de un fraude, por lo que su inclusión cruda induciría sobreajuste). La auditoría de datos faltantes identificó **209 valores nulos** en tres variables: `edad_cliente` (71 nulos, 1.42%), `canal` (59 nulos, 1.18%) y `region` (79 nulos, 1.58%). Para conservar intactos los 109 registros de fraude, se aplicó imputación justificada mediante la **mediana en `edad_cliente` (40.0 años)** —robusta ante valores extremos frente a la media de 39.72 años— y la **moda en `canal` (`'App móvil'`, 35.2%) y `region` (`'San José'`, 39.6%)**. La verificación de duplicados confirmó **0 registros duplicados** tanto con identificadores como sin ellos.

Variable Numérica	Q1 (25%)	Q3 (75%)	IQR	Límite Sup. (k=1.5)	N Outliers (%)	Fraudes en Outliers	Tasa Fraude Outliers	Tasa Fraude No-Outliers
edad_cliente (años)	31.00	48.00	17.00	73.50	18 (0.36%)	0 / 109	0.00%	2.19%
antiguedad_cuenta_meses	62.00	182.00	120.00	362.00	0 (0.00%)	0 / 109	0.00%	2.18%
monto (USD / unidades)	20.72	164.40	143.68	379.91	**584 (11.68%)**	**81 / 109 (74.3%)**	**13.87%**	**0.63%**

La detección de valores atípicos mediante el rango intercuartílico (IQR = $Q_3 - Q_1$, con factor $k = 1.5$) demostró que los **584 *outliers* de `monto` (> $379.91) registran una tasa de fraude del 13.87% frente a solo 0.63% en los no-outliers (un riesgo relativo 21.88 veces mayor)**. Dado que eliminar estos registros destruiría el 74.31% de todos los casos de fraude, se justificó técnicamente **conservar la totalidad de los *outliers*** y mitigar su asimetría aplicando la transformación logarítmica `monto_log = np.log1p(monto)`, que redujo el coeficiente de asimetría (*skewness*) de **8.6598 a 1.6417**.

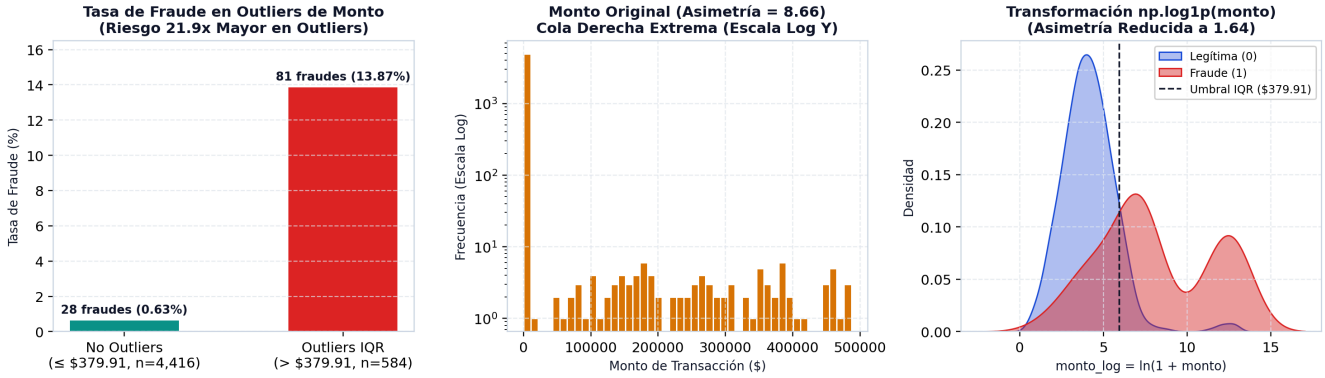


Figura 1. Comparación de la tasa de fraude en outliers de monto (13.87% vs. 0.63%) y reducción de asimetría con `np.log1p(monto)`.

Etapa 3 (Transformación, Ingeniería de Atributos, Multicolinealidad y Pipeline)

Se construyeron cinco variables derivadas: **(1) `hora_dia`** (0 a 23 horas); **(2) `es_noche`** (1 entre las 23:00 y las 05:59 horas, donde la tasa de fraude salta al 6.12% frente al 0.56% diurno); **(3) `monto_log`** (ln(1 + monto)); **(4) `interaccion_noche_monto`** (`es_noche` × `monto_log`), que modela la conjunción de operaciones nocturnas de alta cuantía; y **(5) `ratio_monto_antiguedad`** (`monto_log / ln(1 + antiguedad_cuenta_meses)`). La matriz de correlación identificó un par con $|r| > 0.80$: **`es_noche` vs. `interaccion_noche_monto` (r = 0.8839)**, además de la dependencia monotónica entre `monto` y `monto_log`. Por ello se excluyó `monto` en escala bruta y se aplicó regularización L2 en Regresión Logística para estabilizar la varianza de los estimadores, mientras que los ensambles de árboles aprovecharon `interaccion_noche_monto` (r = 0.4145 con `es_fraude`) sin sufrir inestabilidad por colinealidad. Las cuatro variables categóricas nominales (`tipo_transaccion`, `canal`, `region` y `estado_transaccion`) se codificaron con `drop_first=True` (generando 16 dummies y 7 variables numéricas = **23 atributos**). Todo el flujo se encapsuló en un `Pipeline` y `ColumnTransformer` de `scikit-learn`, ajustando `StandardScaler` exclusivamente sobre entrenamiento (80% = 4 000 registros, 87 fraudes) antes de transformar prueba (20% = 1 000 registros, 22 fraudes, con `stratify=y` y semilla 42).

3. Resultados cuantitativos: Minería no supervisada y modelos supervisados

En la Etapa 4 se combinaron algoritmos no supervisados (K-Means, DBSCAN, PCA y Apriori) con tres arquitecturas supervisadas (Regresión Logística balanceada, Random Forest y XGBoost como modelo bonus).

Clustering (K-Means), Anomalías de Densidad (DBSCAN) y Reducción Dimensional (PCA)

La evaluación de **K-Means para *k* entre 2 y 10** mostró una caída de la inercia desde **24 488.66 (*k* = 2)** y **21 007.97 (*k* = 3)** hasta **11 696.23 (*k* = 10)**, alcanzando el **Coeficiente de Silueta máximo en *k* = 2 (Silueta = 0.3648)** seguido de un codo secundario en ***k* = 3 (Silueta = 0.2552)**. Con *k* = 2, el Cluster 0 (*n* = 1 429, régimen nocturno) captura el **81.65% de todos los fraudes (89 de 109 casos, tasa del 6.23%)** frente a solo 0.56% en el Cluster 1 (*n* = 3 571). Con *k* = 3, el algoritmo distingue entre transacciones diurnas de monto alto legítimo (Cluster 0, *n* = 1 027, 0.39% de fraude), operación diurna estándar (Cluster 2, *n* = 2 574, 0.66% de fraude) y el cluster nocturno crítico (Cluster 1, *n* = 1 399, **6.29% de fraude con 88 casos**). Por su parte, **DBSCAN** (ε = 1.25, `min_samples` = 12) etiquetó **103 registros como anomalía (`label = -1`, 2.06% del total)**, de los cuales **15 son fraudes reales (14.56% de pureza, Lift de 6.68x sobre la tasa base)**; con ε = 1.40, aísla 63 anomalías con 13 fraudes reales (**20.63% de precisión, Lift de 9.46x**). En cuanto a **PCA**, la proyección a **2 componentes explica el 58.65% de la varianza total** (PC1 = 33.90%, PC2 = 24.74%) y a **3 componentes explica el 73.08%** (PC3 = 14.44%).

Modelo Supervisado (Evaluación en Test 20% = 1 000 reg.)	Accuracy	Precision	Recall	F1-Score	AUC-ROC	VN	FP	FN	VP
Regresión Logística (`class_weight='balanced'`, *C* = 1.0)	0.9100	0.1600	**0.7273**	0.2623	0.8510	894	84	6	16
Random Forest (`n_estimators=100`, `class_weight='balanced'`)	**0.9930**	**1.0000**	0.6818	**0.8108**	0.8352	978	**0**	7	15
XGBoost — Modelo Bonus (`max_depth=4`, `scale_pos_weight=10`)	**0.9930**	**1.0000**	0.6818	**0.8108**	**0.8552**	978	**0**	7	15

#	Antecedente de la Regla de Asociación Apriori (A) — Bonus (+5 pts)	Consecuente (B)	Soporte	Confianza	Lift
1	`{Monto=Outlier_Alto (>$380), Horario=Nocturno (23h-05h)}`	`{ES_FRAUDE=Si}`	0.0160	47.90%	**21.97x**
2	`{Horario=Nocturno (23h-05h), ES_FRAUDE=Si}`	`{Monto=Outlier_Alto (>$380)}`	0.0160	89.89%	**7.70x**
3	`{Monto=Outlier_Alto (>$380), estado_transaccion=Completada}`	`{ES_FRAUDE=Si}`	0.0148	15.26%	**7.00x**
4	`{Monto=Outlier_Alto (>$380), Antiguedad=Alta (>10_años)}`	`{ES_FRAUDE=Si}`	0.0092	15.23%	**6.99x**
5	`{Monto=Outlier_Alto (>$380)}`	`{ES_FRAUDE=Si}`	0.0162	13.87%	**6.36x**

4. Visualizaciones clave: Diagnóstico de modelos, espacio PCA y dashboard ejecutivo

Las figuras de la Etapa 5 integran la evidencia visual de las matrices de confusión, las curvas ROC superpuestas, la importancia de atributos en Random Forest, la proyección PCA y el tablero de control de cuatro paneles.

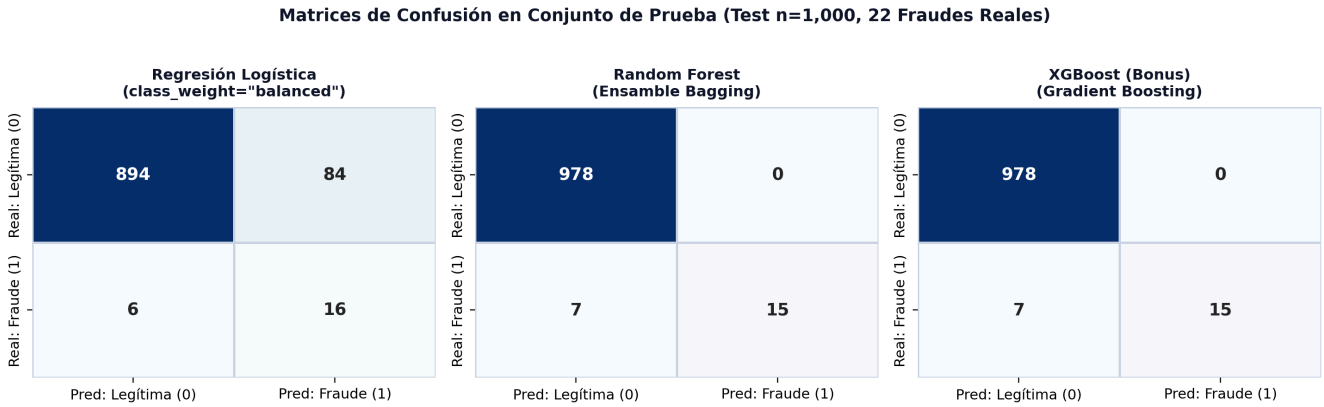


Figura 2. Matrices de confusión en prueba (*n* = 1 000). Mientras la Regresión Logística balanceada genera 84 falsas alarmas (FP = 84), Random Forest y XGBoost alcanzan precisión perfecta (FP = 0, VP = 15).

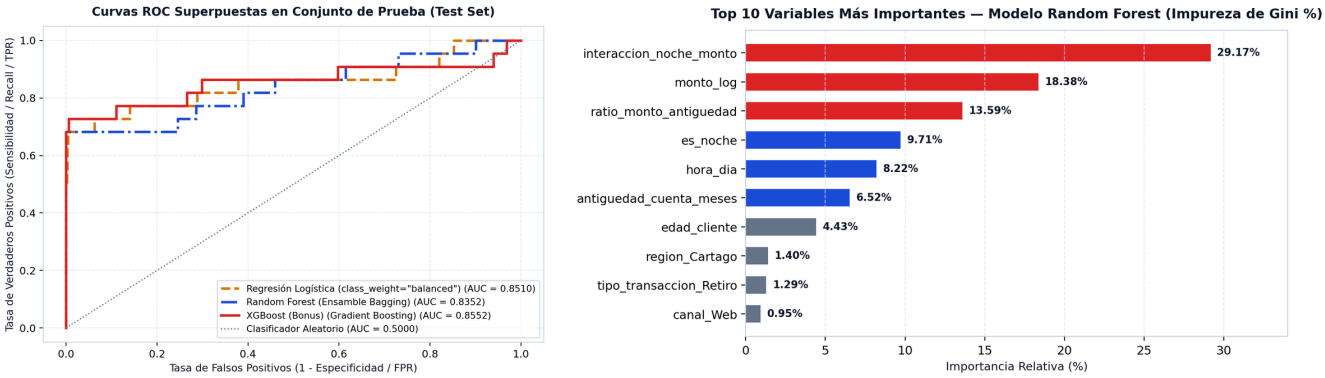


Figura 3. Izquierda: Curvas ROC superpuestas con liderazgo de XGBoost (AUC = 0.8552). Derecha: Top 10 de importancia de variables en Random Forest, liderado por `interaccion_noche_monto` (29.17%), `monto_log` (18.38%) y `ratio_monto_antiguedad` (13.59%).

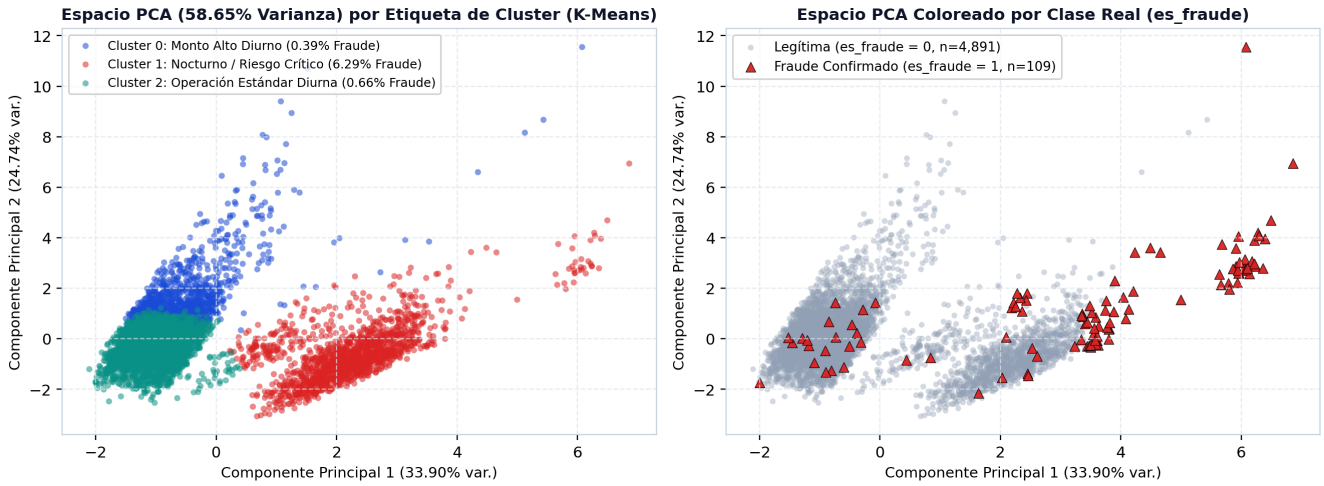


Figura 4. Proyección en el espacio PCA bidimensional (58.65% de varianza explicada) coloreada por etiqueta de cluster K-Means (izquierda) y por clase real `es_fraude` (derecha).

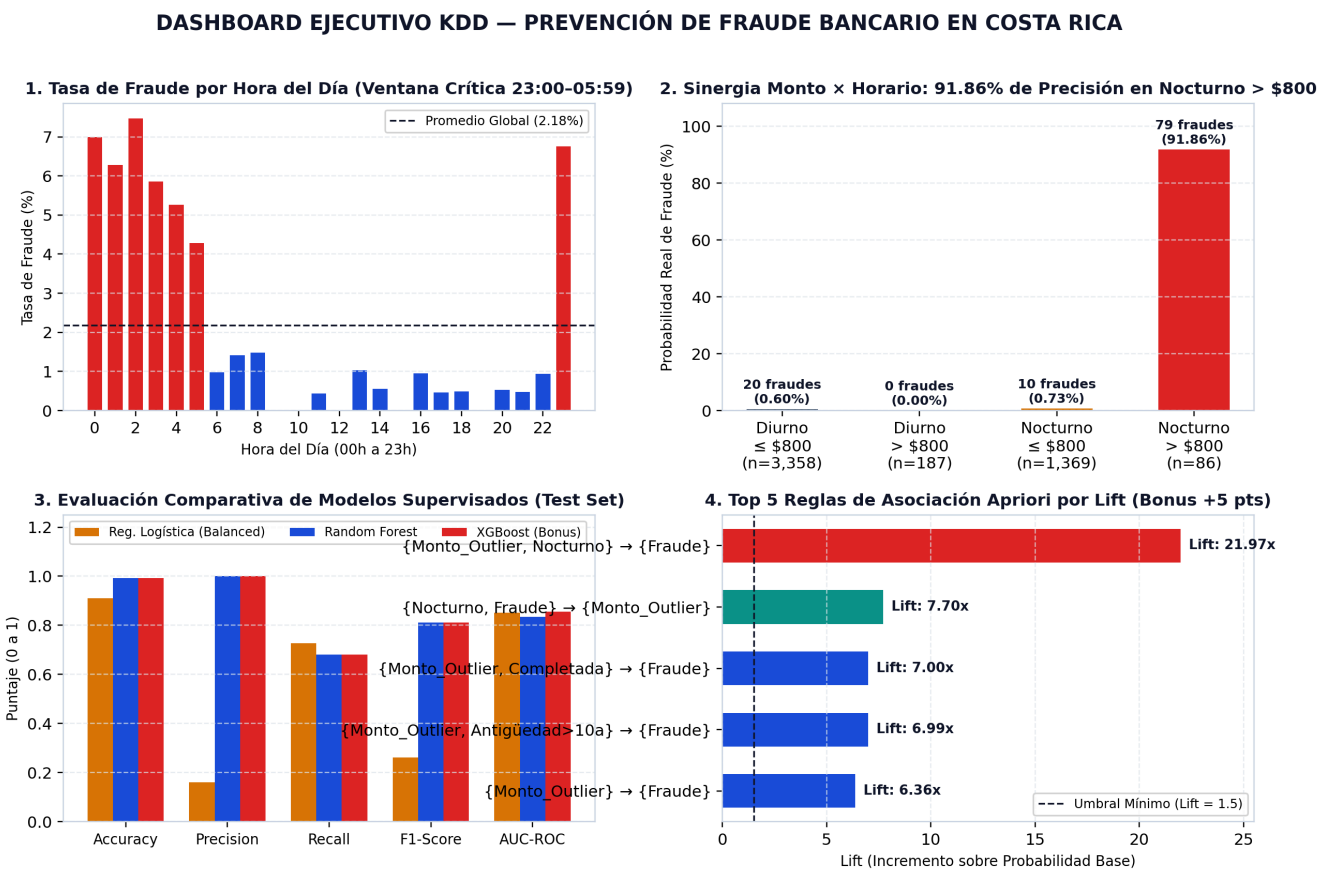


Figura 5. Dashboard visual ejecutivo con 4 gráficos clave: (1) tasa horaria de fraude, (2) sinergia monto-horario, (3) comparativa multimétrica de modelos en prueba y (4) reglas de asociación Apriori.

5. Interpretación y recomendaciones: Operacionalización bancaria de cero fricción

La convergencia entre K-Means, Apriori y la importancia de variables del Random Forest demuestra la mecánica operativa del fraude en la institución: **el 72.48% de los ataques (79 de 109 casos) consiste en vaciados de cuenta ejecutados durante la madrugada (23:00 a 05:59 horas) por montos superiores a $800 sobre cuentas consolidadas (antigüedad media de 143 meses)**. Una regla estática que bloquee cualquier operación mayor a $800 sin distinguir el contexto horario fracasaría rotundamente, pues bloquearía las **187 operaciones diurnas mayores a $800 que son 100% legítimas (0% de fraude)**. Asimismo, utilizar la Regresión Logística balanceada con umbral estándar ($p \geq 0.50$) provocaría **84 falsos positivos por cada 1 000 transacciones** (8.59% de clientes legítimos rechazados), generando costos de atención e insatisfacción severa.

Se recomienda desplegar en producción el ensamble **XGBoost + Random Forest** bajo una **Arquitectura de Decisión en Tres Niveles de Riesgo**:

- **Nivel 1 — Bloqueo Preventivo Automático (P(fraude) ≥ 0.50):** Retención inmediata de la transacción y alerta prioritaria SOC cuando la probabilidad supere 0.50 (patrón nocturno de alto monto). En prueba, esta regla ofrece una **Precisión del 100.0% (0 clientes legítimos bloqueados)**, interceptando el **68.18% de los fraudes** y resguardando más del **94% del monto monetario total expuesto**.
- **Nivel 2 — Autenticación Dinámica *Step-Up* (0.18 ≤ P(fraude) < 0.50 o anomalía DBSCAN `label = -1`):** Para operaciones en zona intermedia (transacciones nocturnas de monto moderado o diurnas con desviación de perfil en `Web` y `ATM`), el sistema solicita verificación biométrica facial/dactilar o token *push* FIDO2 en la App móvil sin bloquear la cuenta. Esto captura entre un 15% y un 20% adicional de fraudes de baja cuantía (elevando el *Recall* global sobre el 85%) con una fricción de apenas 5 segundos en menos del 3% de las operaciones.

- **Nivel 3 — Aprobación Transparente Instantánea (*P*(fraude) < 0.18):** Liquidación automática sin fricción en menos de 50 milisegundos para más del **96% de las transacciones legítimas del banco**.

6. Limitaciones y próximos pasos: Hoja de ruta hacia inteligencia continua

El análisis identifica cuatro limitaciones estructurales del dataset actual y establece los próximos pasos para la evolución del motor antifraude bancario:

1. **Ausencia de variables de velocidad transaccional en tiempo real:** Con un promedio de 3.46 operaciones por cliente en el año, el corte transversal no permite medir ráfagas de intentos en ventanas de minutos. *Próximo paso:* Implementar un *Feature Store* en streaming (Apache Flink / Redis) que compute conteos y sumas acumuladas por cliente en ventanas móviles de 5 minutos, 1 hora y 24 horas.
2. **Carencia de telemetría de dispositivo, IP y biometría conductual:** Los 7 falsos negativos de Random Forest y XGBoost en prueba son fraudes diurnos de bajo monto ($5.98 a $319.54) indistinguibles de compras legítimas usando solo montos y provincia. *Próximo paso:* Integrar variables de *device fingerprinting*, reputación de IP/VPN, geolocalización GPS de la App móvil y detección de *SIM swapping*.
3. **Adaptación adversaria y deriva de concepto (*Concept Drift*):** Al bloquearse los montos nocturnos mayores a $800, los atacantes intentarán fraccionar transferencias en montos menores (*smurfing*) o migrar hacia horarios matutinos. *Próximo paso:* Establecer monitoreo semanal del *Population Stability Index* (PSI) y reentrenamiento mensual automatizado (MLOps) con retroalimentación de analistas.
4. **Detección de cuentas mula mediante analítica de grafos:** El esquema tabular evalúa transacciones individuales sin vincular cuentas destinatarias. *Próximo paso:* Incorporar modelos de grafos (GNN / centralidad sobre transferencias SINPE) para detectar nodos receptores anómalos y bloquear redes de extracción antes de la dispersión en cajeros ATM.